

视觉大模型驱动 机械臂完成分拣任务



课程项目说明




任务、框架、要求与交付



课程项目 | 机器人感知与操作

把黄色香蕉放进紫色圆盘。🍌

把红色苹果放进灰色方盘。🍏



任务：大模型驱动机械臂完成分拣任务

- 输入：自然语言、RGB-D、机械臂状态
- 输出：抓取、放置与物理可验证的分拣结果
- 三个任务：普通形状、真实物体、多物体语义分拣



Task 1: 普通形状



根据语言指令，把指定形状放入指定容器。

Task 2: 香蕉、苹果等真实物体



根据语言指令，把指定真实物体放入指定容器。


Task 3: 多物体按类别分拣



根据类别指令，将多物体分拣到对应容器。

Task 1: 普通形状分拣

- 场景：红方块、绿圆柱、蓝长方体；方盘与圆盘



1 测试点 1：夹起指令指定物体




根据语言指令，
夹起指定的目标物体。

2 测试点 2：放进正确容器，松爪后稳定



将物体**放入对应容器**中，
松爪后物体稳定不倒。

Task 2: 仿真真实物体分拣



测试点 1: 夹起指定香蕉或苹果

- VLM 结合视觉感知与几何, 生成抓取并执行



测试点 2: 放进正确容器, 松爪后稳定

- 放置到正确目标容器中, 松爪后物体保持稳定

香蕉的物理与碰撞近似



网格模型



凸包分解



碰撞近似

背景 1：视觉大模型

- VLM 理解自然语言任务
- VLM 在当前视觉候选中选择对象与容器
- 检测、三维几何、控制和验证仍由专门模块完成

视觉大模型 (VLM) 的职责



指令理解

理解自然语言任务与约束，明确目标对象与容器类型。



候选选择

在当前视觉候选中，选择最合适的对象与容器。



高层计划

输出结构化目标与高层步骤，指导后续几何与控制模块。



接口输出



结构化目标
与高层计划



执行反馈

状态、验证结果、
异常信息等

几何与控制模块的职责 (不可替代)



感知与三维重建

RGB-D 获取、目标检测 (YOLO)、分割 (SAM)、点云生成与配准。



几何与控制

坐标系转换、数值 IK、轨迹生成、碰撞检测与抓取/放置执行。



验证与闭环

基于物理状态验证 (PREGRASP/GRASP/PLACE/VERIFY)，驱动重试或下一步决策。

背景 2：视觉大模型如何用于分拣

1



任务理解：对象、属性和目标容器

- 解析自然语言指令，提取关键信息
- 确定要操作的对象与目标容器

问题：抓什么？放哪里？



2



识别与指代：在当前候选中选择对象与容器

- 基于 RGB-D 图像与候选（SAM/YOLO 等）
- 将语言指代对齐到具体实例与容器

问题：当前看到的哪个才是它们？



3



高层规划：决定抓什么、放哪里、何时重观察

- 输出高层动作序列：抓取 → 移动 → 放置 → 验证
- 何时重观察、失败后如何调整

问题：下一步做什么？

```
{
  "plan": ["PREGASP", "GRASP",
    "MOVE", "PLACE", "VERIFY"],
  "target": "banana_1",
  "place": "tray_round_purple",
  "reobserve": true
}
```



核心价值：将自然语言指令转化为可执行的视觉-动作计划，支撑机械臂完成分拣任务。

VLM 调用示例：Prompt 与 Response

Prompt (发送给模型)

任务：把黄色香蕉放进紫色圆盘。

候选物体：fruit_1 = banana; fruit_2 = apple

 fruit_1 = banana;  fruit_2 = apple

候选容器：tray_round; tray_square

 tray_round;  tray_square

仅返回 JSON: target_id、place_id、reason




Response (模型返回)

```
{"target_id": "fruit_1", "place_id": "tray_round",  
  "reason": "黄色香蕉对应 fruit_1; 紫色圆盘对应 tray_round."}
```

结构化输出便于记录、检查和失败分析；后续模块只使用候选 ID 与视觉几何结果，不读取真值坐标。

背景 3：机械臂结构


- Franka Panda 七自由度机械臂
- 平行夹爪负责接触与抓取
- overhead/front RGB-D、方盘与圆盘构成任务场景



i 系统由双视角 RGB-D 相机、Franka Panda 七自由度机械臂、平行夹爪以及桌面上的物体与容器组成。

背景 4：机械臂运动控制

- 策略输出末端增量或目标位姿
- 动作限幅后通过数值 IK 求解关节目标
- 夹爪和关节命令受关节范围、接触和重力约束



物理与约束条件
(策略不可直接修改)



关节范围限制

每个关节的最小/最大角度



碰撞约束

与环境/自身的碰撞检测



接触约束

摩擦、接触力与非穿透




重力约束

质量与重力影响



控制链总结：高层动作 → 末端目标 → 限幅 → 数值 IK → 关节/夹爪命令 → MuJoCo 物理执行 → 新状态

背景 5：物理限制与难点



碰撞、接触、重力与摩擦
会改变轨迹和抓取稳定性



重感知
重规划



形体和 prompt 变化
不能用固定模板解决



重感知
重规划



前一步碰倒物体
会改变后续场景



重感知
重规划



每一步需要验证
重感知与重规划



验证
重感知
重规划




物理世界的不确定性 + 长序列任务的级联效应 $\Rightarrow$ 必须闭环：验证 $\rightarrow$ 重感知 $\rightarrow$ 重规划 $\rightarrow$ 再执行

项目框架总览

• 输入：指令、双视角 RGB-D、机械臂状态

• 感知与决策：VLM、检测/分割、深度与标定

• 执行与验证：规划、IK、夹爪、重新观察



框架 1：环境、输入与信息边界

- 可用：语言、RGB-D、本体状态、公开任务字典和自己的中间结果
- 禁止：目标真值、物体真值坐标、真值 mask、成功谓词
- 禁止按随机种子回放固定轨迹

✓ 可用信息（自动策略可使用）



语言指令

例：把香蕉放进紫色圆盘

RGB-D观测

RGB



深度图



本体状态

关节位置/速度

$$q, \dot{q} \in \mathbb{R}^n$$

末端位姿（可选）

$$T_{ee} \in SE(3)$$

开放词汇

物体类别



容器类别



中间结果
(自己计算)

分割Mask
点云/深度
候选抓取位姿
轨迹/日志
历史记录
.....

✗ 禁止信息（自动策略不得使用）



目标真值

评测目标 ID
或类别标签
(仅评测器可见)

如：当前应抓取的是 banana



物体真值坐标

物体在世界/相机坐标下的真实位姿
(仅评测器可见)

如： T_{world}^{obj}



真值 mask

评测器提供的像素级真值掩码
(仅评测器可见)



成功谓词

是否成功的评测结果
(仅评测器可见)

SUCCESS = True



固定轨迹回放

按随机种子回放预录的控制序列

seed replay trajectory



核心原则：在随机初始化场景下，只能依据当前观测（语言、相机、本体状态）进行闭环决策与验证。

框架 2：感知与三维几何

- VLM、SAM、YOLO 或等价方法生成语义候选
- mask、深度和相机标定恢复三维位置与表面信息
- 基于当前形体和容器区域产生抓取/放置候选

1. RGB 图像与语言




把黄色香蕉放进紫色圆盘。



📷 RGB 图像 📷 深度图 (D)

2. 类别 / 实例候选




VLM / YOLO → 语义候选

3. mask 与深度

实例级 mask




对齐深度图



近 远

4. 相机 → 工作空间

相机内参 K , 外参 $[R|t]$




反投影 → 点云 / 坐标转换

5. 抓取点与放置区域

抓取候选 (6-DoF)




放置候选 (容器区域)



抓取 / 放置候选集


框架 3：规划与控制

- PREGRASP：到目标上方安全位姿
- DESCEND + CLOSE：下降、合爪、检查接触
- LIFT + PLACE：抬升，移动到指定盘上方
- VERIFY：松爪，确认盘内稳定；失败则重规划



框架 4：异步、验证与评测



- MuJoCo 以 25 Hz 持续推进
- 远端 VLM/SAM 在异步 worker 中运行，不阻塞物理
- 只接受对应最新观测的结果；过期结果丢弃
- 记录输入、输出、时间戳与验证结果，定位失败环节



原则：只使用语言、相机图像/深度、本体状态与任务字典；不读取任何真值。

手动遥控模式：用于调试

键盘控制映射



调试检查清单



1 工作空间检查

末端能否到达目标物体和容器区域？



2 IK 可达性检查

目标位姿是否可达？姿态是否合理？



3 碰撞检测

运动过程中是否与桌面、容器或物体碰撞？



4 抓取高度检查

抓取高度是否合适？会否碰撞或打滑？



5 容器位置检查

容器位置是否正确？放置姿态是否合适？



遥控仅用于调试，不构成自动策略成绩。

要求 1：禁止写死与特权信息

- 禁止写死物体/托盘坐标、读取真值或成功谓词
- 禁止按 seed 回放轨迹、改评测器或只保留成功视频
- 正确做法：从当前观测感知、规划、执行、验证，并提交原始日志

❌ 不允许的捷径（示例）



写死坐标

- ✗ 直接硬编码物体坐标
- ✗ 不使用视觉识别



按 seed 回放

- ✗ 直接固定随机种子
- ✗ 回放成功历史轨迹



改评测器


- ✗ 修改评测器代码



只保留成功视频

- 需要包含设计讲解
- 失败案例分析

✅ 正确做法：感知—规划—执行—验证闭环




信息边界（自动策略仅可使用）

语言指令，RGB-D图像，本体状态，公开任务字典和自己计算的中间结果；不能直接读取仿真器目标真实坐标、真实Mask或者评测器结果

要求 2：必须有大模型感知、识别与规划

- 保存模型所见图像/候选、prompt 和结构化输出
- 模型输出必须影响对象/容器选择、动作顺序或失败后的下一步（仅调试/设计建议，不一定要提交）
- 用几何、IK 和物理执行；用新观测验证结果



资源



硬件算力

- 一般电脑可运行 MuJoCo 和基础项目；训练 VLA 时可租 GPU



模型接口

- OpenAI-compatible 接口可接入 Qwen、DeepSeek 等视觉模型

Qwen

DeepSeek



感知与控制工具

- SAM、YOLO、RGB-D、标定、数值 IK 和日志均可作为工具



SAM



YOLO



RGB-D



数值 IK

评分标准

维度	关注点	由基础到高质量的递进（示例）	说明
 1. 基础可运行	- 环境安装与启动 - 代码结构清晰 - 接口/配置正确	无法运行 部分运行 能跑通流程 稳定可复现  能启动 MuJoCo, 加载场景, 机械臂可运动, 日志/可视化可用。	✓ 有可运行的脚本与说明 ✓ 基础功能无硬错误
 2. 闭环可复查	- 感知—规划—执行—验证 - 关键日志与可视化 - 失败处理与恢复	开环/不完整 闭环但不稳定 闭环可运行 闭环可复查  完整闭环: PREGRASP → 抓取 → 搬运 → 放置 → VERIFY。	✓ 关键中间结果可视化 ✓ 日志完整、可复现 ✓ 有失败处理机制
 3. 任务表现	- Task 1/2 夹起与放置 - 随机场景表现 - 稳定性与鲁棒性	几乎不成功 偶尔成功 较高成功率 稳定高成功率  在随机初始化场景下, 正确夹起目标并放到对应容器中, 结果被物理验证通过。	✓ Task 1/2 成功率高 ✓ 对随机干扰更鲁棒 ✓ 运行稳定、波动小
 4. 实验与工程	- 对照实验与消融 - 失败分析 - 工程质量与复现性	无分析 有对比 有深入分析 完整深入  包含对比/消融、失败案例分析与改进讨论, 工程化程度高, 易复现。	✓ 有实验对比与讨论 ✓ 失败分析有洞见 ✓ 代码规范, 文档清晰



总体原则：基础可运行即可获得基础分；闭环质量与稳定性决定上限；表现越好、分析越深入、工程越规范，加分越多。

拓展

✓ 可选拓展方向（可结合课程内容，鼓励系统性创新）

1) VLA: 视觉—语言—动作模型

把黄色香蕉
放进紫色圆盘。

RGB-D 图像

机械臂状态

任务字典

VLA
模型



感知 → 规划 → 执行 → 验证 (闭环)

2) 移动与操作: 狗背机械臂 / 轮臂



感知 → 规划 → 执行 → 验证 (闭环)

3) 人形平台 / 灵巧手抓取



感知 → 规划 → 执行 → 验证 (闭环)



纯世界模型/SLAM等单点研究

不以完成抓取/分拣为目标的研究方向不接受。



偏离主题

必须围绕“抓取/分拣 + 视觉闭环”展开。



拿已有项目直接提交

成果必须是本课程期间产生。



拓展可以结合课程内容，但成果必须是本课程期间产生、围绕抓取/分拣，且包含感知—规划—执行系统闭环。

最终交付

需要提交的材料



1. 代码与环境

可运行代码、环境说明、配置、日志与可复现命令；



2. 报告

方法、设计、实现细节、实验结果、消融与分析



3. 视频

完整任务执行视频（含初始化、执行、验证），失败案例与分析



4. 成员贡献说明

每位成员贡献比例与分工说明

提交前

提交前检查



可运行

按照说明可以完整运行任务，得到日志、视频与验证结果。



可解释

关键决策、模块作用与失败原因清晰，报告逻辑自洽。



可复现

在相同配置与随机种子下结果一致，或在多次运行中具有稳定性。



允许使用 AI Agent: 可以使用 AI Agent 辅助实现与写作，但最终结果必须可运行、可解释、可复现。提交者需对成果负责。

